



Indexação de DataFrames em Python

Construindo o Baralho (Produto Cartesiano)

Criamos todas as combinações entre faces e naipes usando o produto cartesiano. Isso gera exatamente 52 cartas — as 13 faces multiplicadas pelos 4 naipes.

Percorremos os naipes e, dentro de cada naipe, as 13 faces. O resultado é armazenado em um DataFrame com colunas nomeadas.

```
import numpy as np
import pandas as pd

faces = ["ás", "dois", "três", "quatro", "cinco", "seis",
         "sete", "oito", "nove", "dez", "valete", "dama", "rei"]
naipes = ["ouros", "copas", "paus", "espadas"]
baralho = pd.DataFrame(
    [(f, n) for n in naipes for f in faces],
    columns=["face", "naipe"]
)
baralho.head()
```

❏ Saída esperada:

	face	naipe
0	ás	ouros
1	dois	ouros
2	três	ouros
3	quatro	ouros
4	cinco	ouros

Criando e Atribuindo uma Nova Coluna

A função `np.tile` repete a sequência de 1 a 13 quatro vezes, uma para cada naipe, atribuindo o valor numérico de cada carta. Essa abordagem é simples e eficiente para adicionar informações estruturadas.

```
baralho["valor"] = np.tile(np.arange(1, 14), 4)
```

```
baralho.head()
```

Saída esperada:

```
face  naipe  valor
0  ás    ouros  1
1  dois  ouros  2
2  três  ouros  3
3  quatro ouros  4
4  cinco ouros  5
```

Formas de Acesso a Tabelas

iloc: Posição

Acesso baseado em índices numéricos de linhas e colunas

```
baralho.iloc[0, 1]
```

loc: Nome

Acesso usando rótulos de índice e nomes de colunas

```
baralho.loc[0, "naipe"]
```

Condição

Filtragem usando expressões booleanas

```
baralho[baralho["valor"] > 10]
```

Esses três métodos cobrem os principais padrões de indexação no pandas, permitindo flexibilidade no acesso aos dados.

📄 **Saídas esperadas:** 'ouros', 'ouros', e DataFrame com valetes, damas e reis

Colunas como Vetores (Séries)

Quando acessamos uma única coluna de um DataFrame, o resultado é uma **Série** — uma estrutura unidimensional que se comporta como um vetor.

Séries mantêm o índice original e permitem operações vetorizadas eficientes.

```
baralho.iloc[0, 0]  
baralho["face"].iloc[[0, 1]]  
baralho["face"].head()
```

 **Saída esperada:**

```
'ás'  
0 ás  
1 dois  
Name: face, dtype: object
```

Múltiplas Formas de Acessar Colunas

O pandas oferece diferentes sintaxes equivalentes para acessar os mesmos dados. Podemos escolher a forma mais clara e legível conforme o contexto do código.

loc com nomes

```
baralho.loc[[10, 13], "face"]
```

iloc com posições

```
baralho.iloc[[10, 13], 0]
```

Coluna + iloc

```
baralho["face"].iloc[[10, 13]]
```

📄 **Resultado:** Todas retornam a mesma Série com 'valete' e 'ás'

Acessando Múltiplas Colunas

Quando selecionamos **mais de uma coluna**, o pandas retorna um DataFrame em vez de uma Série. Isso preserva a estrutura tabular e a relação entre as variáveis.

Use listas duplas de colchetes para garantir que o resultado seja sempre um DataFrame.

```
baralho.iloc[10:12, 0:2]  
baralho.loc[[10, 13], ["face", "naipe"]]
```

Saída esperada:

```
face  naipe  
10 valete ouros  
11 dama  ouros  
  
face naipe  
10 valete ouros  
13 ás copas
```

Série vs DataFrame

Uma coluna: Série

Colchetes simples retornam uma Série unidimensional

```
type(baralho["face"])
```

Resultado: pandas.core.series.Series

Uma coluna: DataFrame

Colchetes duplos preservam a estrutura de tabela

```
type(baralho[["face"]])
```

Resultado: pandas.core.frame.DataFrame

Essa distinção é importante ao encadear operações que esperam um formato específico.

Exclusão de Linhas e Colunas

No pandas, usamos o método `drop()` para remover linhas ou colunas pelo rótulo. Atenção: em Python, índices negativos não removem nada; `x[-1]` significa o último elemento.

Remover linhas

```
baralho.drop(index=range(3))
```

Remove as três primeiras linhas

Remover colunas

```
baralho.drop(columns=["face"])
```

Remove a coluna 'face'

❏ `drop()` retorna um novo DataFrame. Para manter o resultado, reatribua: `baralho = baralho.drop(columns=["face"])`.

Selecionando Linhas e Colunas Inteiras

Podemos acessar dimensões completas da tabela: uma linha inteira, uma coluna inteira ou o DataFrame completo.

Essas operações são fundamentais para análise exploratória e transformações de dados.

```
baralho.iloc[0]  
baralho["naipe"].head()
```

Saídas:

```
face ás  
naipe ouros  
valor 1  
Name: 0, dtype: object  
  
0  ouros  
1  ouros  
2  ouros  
3  ouros  
4  ouros  
Name: naipe, dtype: object
```

Indexação Lógica para Filtrar Colunas

Podemos usar **vetores booleanos** para escolher quais colunas manter. Cada valor `True` indica uma coluna que deve aparecer no resultado.

Essa técnica permite filtros dinâmicos baseados em condições complexas.

```
mask = [True, True, False]  
baralho.loc[:, mask]
```

 **Resultado:** DataFrame contendo apenas as colunas 'face' e 'naipe'

```
face  naipe  
0 ás   ouros  
1 dois ouros  
2 três ouros  
3 quatro ouros  
4 cinco ouros  
...
```

Indexação Lógica para Filtrar Linhas

Criamos uma **máscara booleana** com base em uma condição. Essa máscara determina quais linhas permanecem no DataFrame resultante.

É a forma mais comum e poderosa de filtrar dados no pandas.

```
filtro = baralho["valor"] < 3  
baralho[filtro]
```

 **Resultado:** Apenas cartas com valor menor que 3 (ases e dois)

```
face naipe valor  
0 ás ouros 1  
1 dois ouros 2  
13 ás copas 1  
14 dois copas 2  
...
```

Embaralhando o Baralho

Criamos uma permutação aleatória dos índices usando NumPy. Depois, usamos essa ordem para reorganizar completamente o DataFrame.

Gerar permutação

Cria uma sequência aleatória de índices

Aplicar ao DataFrame

Usa `iloc` para reordenar as linhas

Obter resultado

Retorna o baralho embaralhado

```
ordem = np.random.permutation(len(baralho))  
cartas = baralho.iloc[ordem]  
cartas.head()
```

 **Saída:** Cartas em ordem aleatória (varia a cada execução)

Encapsulando em uma Função

Transformamos o código em uma **função reutilizável** que aceita qualquer DataFrame e retorna uma versão embaralhada.

Isso promove o princípio DRY (Don't Repeat Yourself) e facilita manutenção.

```
def embaralhar(df):  
    ordem = np.random.permutation(len(df))  
    return df.iloc[ordem]
```

```
embaralhar(baralho).head()
```

📄 **Vantagens:** Código modular, testável e reutilizável em diferentes contextos

Tipos de Dados (dtype)

Arrays NumPy e colunas pandas possuem tipos internos que determinam como os dados são armazenados na memória e qual a precisão numérica disponível.

int64

Números inteiros

```
a = np.array([1, 2, 3])  
a.dtype  
# dtype('int64')
```

float64

Números com casas decimais

```
b = np.array([1.0, 2.0, 3.0])  
b.dtype  
# dtype('float64')
```

Conhecer os tipos ajuda a otimizar memória e evitar erros de precisão em cálculos.

Broadcasting, Visão e Cópia

Broadcasting

NumPy combina arrays de formas compatíveis: cada dimensão deve ser igual ou valer 1. Escalares se expandem para todo o array. Formas incompatíveis geram erro, sem repetição automática.

```
x = np.array([1, 2, 3, 4])
y = x[0:2]      # visão
z = x[0:2].copy() # cópia

y[0] = 99
x, y, z
```

View (Visão)

Algumas indexações criam uma **visão** dos dados originais. Modificar a visão afeta o array original.

Copy (Cópia)

Outras indexações criam uma **cópia real** dos dados. Modificações não afetam o array original.

```
x = np.array([1, 2, 3, 4])
x + 10      # array([11, 12, 13, 14])
# x + np.array([1, 2])
# ValueError: operands incompatible for broadcasting
```

📄 **Resultado:** (array([99, 2, 3, 4]), array([99, 2]), array([1, 2]))

Note que modificar **y** alterou **x**, mas **z** permaneceu inalterado.

Indexação por Lista de Índices

Podemos selecionar e reordenar dados usando **vetores de índices**. Isso permite amostragem personalizada e reordenação controlada dos elementos.

Essa técnica é poderosa para criar subconjuntos específicos ou reorganizar dados conforme necessário.

```
x = np.array([10, 20, 30, 40, 50])  
idx = [0, 2, 4]  
x[idx]
```

📄 **Saída esperada:** `array([10, 30, 50])`

Os elementos nas posições 0, 2 e 4 foram extraídos. Diferente do fatiamento (`x[0:2]`), indexar com uma lista sempre cria uma cópia: alterar o resultado não afeta `x`.

Referências

Think Python

Downey, A. *Think Python: How to Think Like a Computer Scientist*. O'Reilly Media.

Uma introdução essencial aos fundamentos de programação e pensamento computacional usando Python.

Python Data Science Handbook

VanderPlas, J. *Python Data Science Handbook*. O'Reilly Media.

Um guia abrangente das ferramentas essenciais para trabalhar com dados em Python, incluindo NumPy, Pandas e bibliotecas de visualização.

Data Science from Scratch

Grus, J. *Data Science from Scratch*. O'Reilly Media.

Aprenda os fundamentos de ciência de dados construindo algoritmos e ferramentas do zero usando Python.