

Manipulação de Dados com Pandas



Eduardo Ogasawara

<https://eic.cefet-rj.br/~eogasawara>



Criando uma Tabela Básica

Criamos colunas numéricas e categóricas usando vetores do NumPy. Esses vetores são combinados em uma estrutura tabular chamada DataFrame, que permite operações de filtragem e análise.

```
import numpy as np
import pandas as pd

weight = np.array([60, 72, 57, 90, 95, 72])
height = np.array([1.75, 1.80, 1.65, 1.90, 1.74, 1.91])
subject = np.array(["A", "B", "C", "D", "E", "F"])

d = pd.DataFrame({
    "weight": weight,
    "height": height,
    "subject": subject
})
```

Estrutura Tabular de Dados

Colunas

Cada coluna representa uma variável

Linhas

Cada linha representa um indivíduo

Operações

Permite análises estatísticas e seleção

```
print(d.dtypes)
```

```
weight int64
```

```
height float64
```

```
subject object
```

Criando uma Tabela Auxiliar

Segunda tabela com dados complementares, associando cada sujeito a um estado.

```
subject = np.array(["A", "B", "C", "D", "E", "F"])
state = np.array(["RJ", "SP", "MG", "RJ", "SP", "MG"])

ds = pd.DataFrame({
    "subject": subject,
    "state": state
})
```

subject	state
A	RJ
B	SP
C	MG
D	RJ
E	SP
F	MG

Tabela Principal e Tabela Auxiliar

Tabela Principal

Dados físicos: peso e altura

Chave Comum

Coluna `subject`

Tabela Auxiliar

Dados geográficos: estados

Ambas as tabelas compartilham a chave `subject`, que permitirá a junção entre elas.

Integração de Dados por Junção

Identificar chave

Coluna `subject`

Combinar linhas

Junção das tabelas

Resultado completo

Todas as colunas reunidas

```
dsm = pd.merge(d, ds, on="subject")
```

subject	weight	height	state
A	60	1.75	RJ
B	72	1.80	SP
C	57	1.65	MG
D	90	1.90	RJ
E	95	1.74	SP

Por padrão, merge faz junção interna (`how="inner"`): só ficam os sujeitos presentes nas duas tabelas. Use `how="left"` para manter todas as linhas da tabela principal.

O Poder das Transformações

Entrada

Dados brutos

Transformação

Operações encadeadas

Saída

Informação estruturada

Um conjunto de dados pode ser transformado passo a passo. Cada operação recebe dados e produz novos dados, criando um pipeline claro e organizado.

```
resultado = (  
  dsm[dsm["height"] > 1.7]  
  [["subject", "weight", "height"]]  
  .sort_values("height")  
)
```

As mesmas etapas dos próximos slides, encadeadas em uma única expressão.

Filtragem de Linhas

Filtrar significa selecionar linhas baseado em uma condição lógica. Aqui selecionamos pessoas com altura maior que 1.7m.

```
filtered = dsm[dsm["height"] > 1.7]
```

❏ O resultado é um subconjunto do DataFrame original com apenas as linhas que atendem à condição.

subject	weight	height	state
A	60	1.75	RJ
B	72	1.80	SP
D	90	1.90	RJ
E	95	1.74	SP
F	72	1.91	MG

Seleção de Colunas

Antes

subject, weight, height, state

Selecionar colunas reduz a tabela ao que é relevante para a análise.

```
selected = filtered[["subject", "weight", "height"]]
```

subject	weight	height
A	60	1.75
B	72	1.80
D	90	1.90
E	95	1.74
F	72	1.91

Depois

subject, weight, height

Ordenação de Dados

Ordenar reorganiza as linhas segundo um critério. Aqui usamos a altura em ordem crescente.

```
ordered = selected.sort_values(  
    by="height"  
)
```

subject	weight	height
E	95	1.74
A	60	1.75
B	72	1.80
D	90	1.90
F	72	1.91

Agregação por Grupos

Agrupar significa dividir os dados em categorias. Cada grupo pode ser analisado separadamente, permitindo comparar regiões.

```
grouped = dsm.groupby("state").agg(  
    count=("subject", "count"),  
    height=("height", "mean")  
)
```

MG

2 sujeitos · Altura média: 1.78m

RJ

2 sujeitos · Altura média: 1.83m

SP

2 sujeitos · Altura média: 1.77m

Interpretação dos Resultados

3 Estados	2 Sujeitos	1.83m	state	count	height
Grupos analisados	Por estado	Maior média (RJ)	MG	2	1.780
Cada linha representa um estado. count indica sujeitos e height a altura média.			RJ	2	1.825
			SP	2	1.770

Dados Prontos para Análise

Filtrar

Selecionar

Ordenar

Agregar

Após as transformações, os dados estão estruturados e prontos para análises avançadas e visualizações.

Referências

Think Python

Downey, A. *Think Python: How to Think Like a Computer Scientist*. O'Reilly Media.

Introdução essencial à programação e ao pensamento computacional com Python.

Python Data Science Handbook

VanderPlas, J. *Python Data Science Handbook*. O'Reilly Media.

Guia completo das ferramentas essenciais para ciência de dados com NumPy, Pandas e visualização.

Data Science from Scratch

Grus, J. *Data Science from Scratch*. O'Reilly Media.

Aprenda fundamentos de ciência de dados construindo algoritmos do zero com Python.